GNN XAI 해석

SimpleCatHeteroGAT + BCE + Edge-split

분석 대상 선택

Test 소송 쌍

#1 6333624 → 6212079 (0.994)

원고: `6333624` **피고:** `6212079` **P(sue):** **0.994** **Threshold:** `0.65` **예측:** ✅ 소송 예측

실행할 방법 선택

- [x] M1 Attention Visualization
- [x] M2 Grad-CAM
- [x] M3 Counterfactual
- [x] M4 GNNExplainer (느림 ~30초)
- [x] M5 PGExplainer (느림 ~20초)
- [x] M6 SubgraphX (느림 ~2분)
- [x] M7 GraphSHAP (느림 ~1분)

🚀 분석 실행

총 test 엣지: 251개

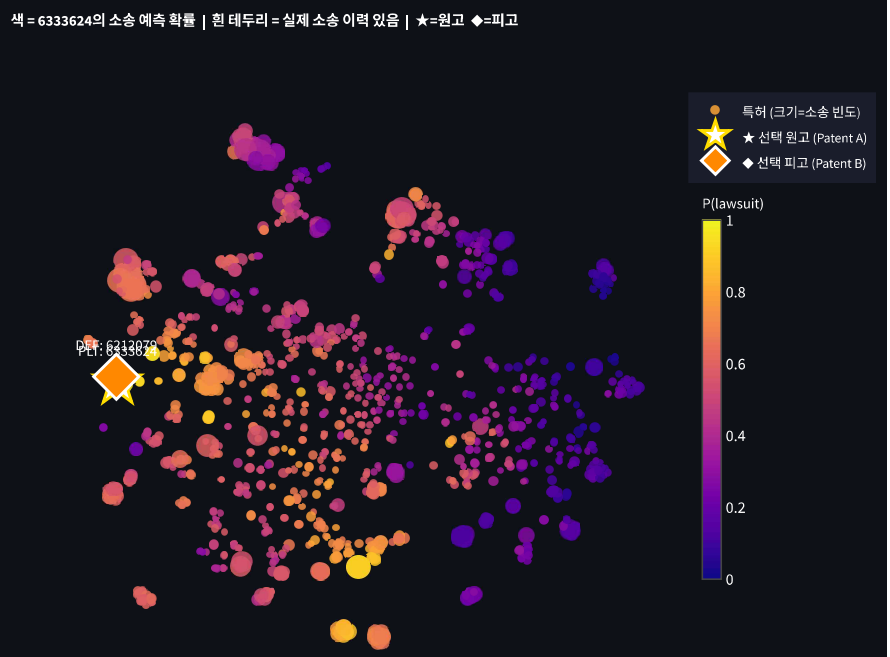
Threshold 초과 예측: 208개

특허 소송 링크 예측 XAI 해석

모델	Test AUROC	Best Threshold	Best Val F1
Simple…	0.9281	0.65	0.8471

Patent Embedding Space (t-SNE)

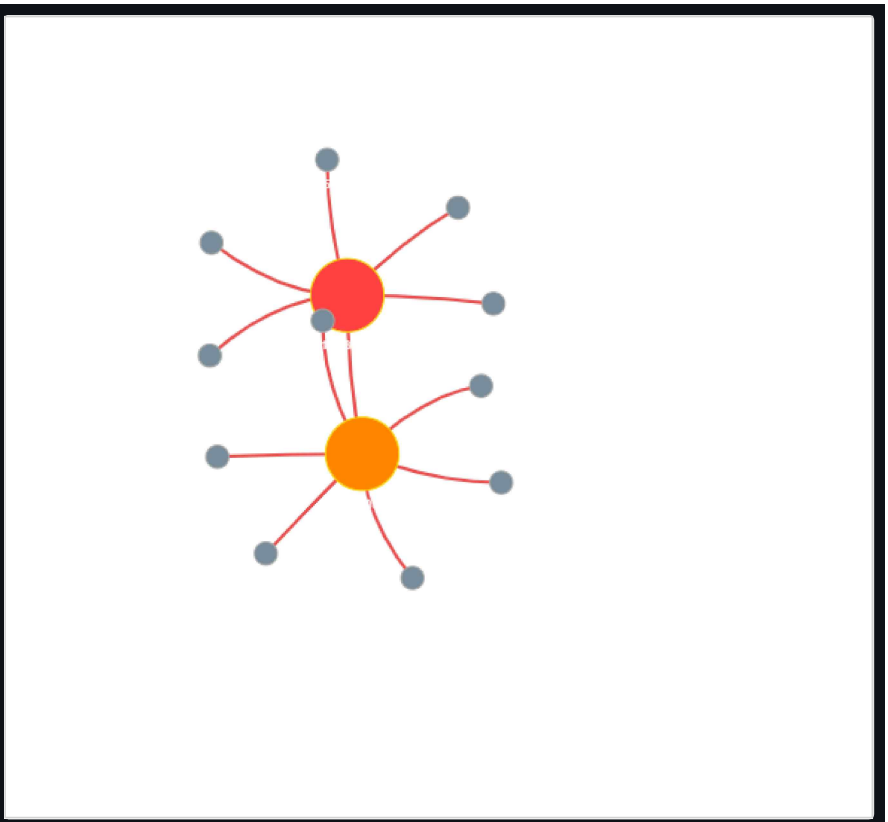
GNN이 학습한 64d 임베딩을 2D로 투영 — 가까울수록 소송 관계가 예측됨



읽는 법

Explanation Subgraph (PyVis)

원고-피고 주변 서브그래프 — XAI 결과(M3·M6)를 먼저 실행하면 엣지·노드에 반영됨



읽는 법

🔎 XAI 방법별 분석

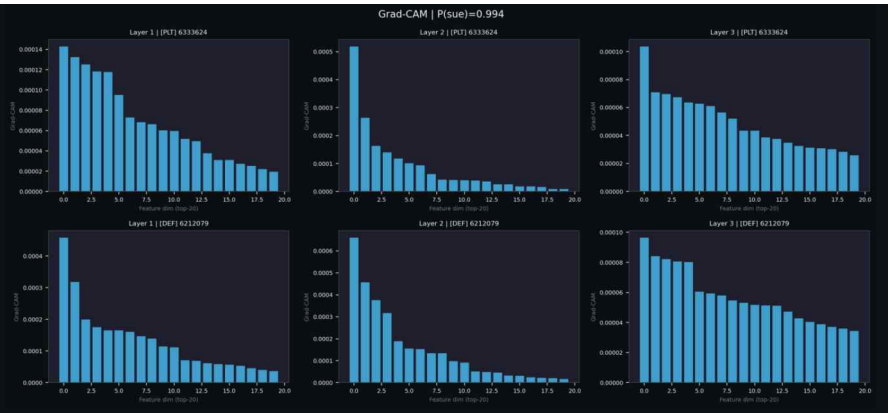
M1. Attention Visualization in GAT

각 GAT 레이어에서 edge type별 attention weight 추출
→ 어떤 이웃 노드가 임베딩 형성에 가장 많이 기여했는지 시각화



M2. Grad-CAM for Link Prediction

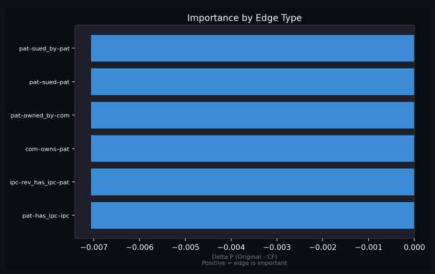
score = sigmoid(h_src · h_dst) 에 대한 gradient × activation
→ 레이어별로 어떤 피처 차원이 소송 예측에 기여했는지 시각화



Layer 1 PLT	Layer 2 PLT	Layer 3 PLT
0.001	0.002	0.002
Layer 1 DEF	**Layer 2 DEF**	**Layer 3 DEF**
0.003	0.003	0.002

M3. Counterfactual Explanations

> 각 edge type의 엣지를 제거했을 때 소송 예측 확률 변화
> → 확률 감소가 클수록 그 연결 관계가 예측에 중요함





Edge Type	Removed	Original P	CF P	Delta
pat–has_ipc–ipc	3	0.992749	0.999813	-0.007064
ipc–rev_has_ipc–pat	3	0.992749	0.999813	-0.007064
com–owns–pat	2	0.992749	0.999813	-0.007064
pat–owned_by–com	2	0.992749	0.999813	-0.007064
pat–sued–pat	18	0.992749	0.999813	-0.007064
pat–sued_by–pat	18	0.992749	0.999813	-0.007064

M4. GNNExplainer (Link Prediction)

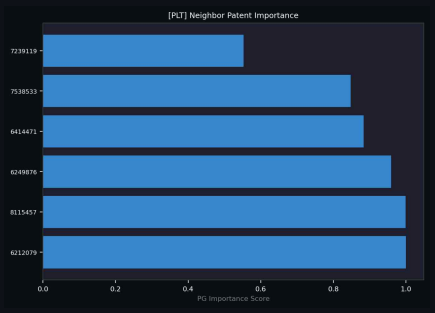
> 예측 확률을 최대화하는 edge mask를 학습합니다 (Straight-Through Estimator)
> → mask prob이 높을수록 예측에 필수적인 연결



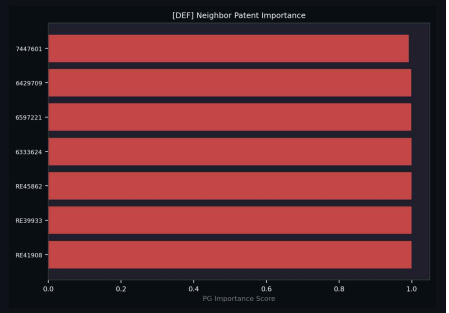
M5. PGExplainer

> MLP(h_i ‖ h_j) → [0,1] 를 학습해 이웃 노드 중요도를 파라미터화합니다
> → 원고/피고 주변에서 소송 예측에 기여하는 특허를 식별

Plaintiff: 6333624

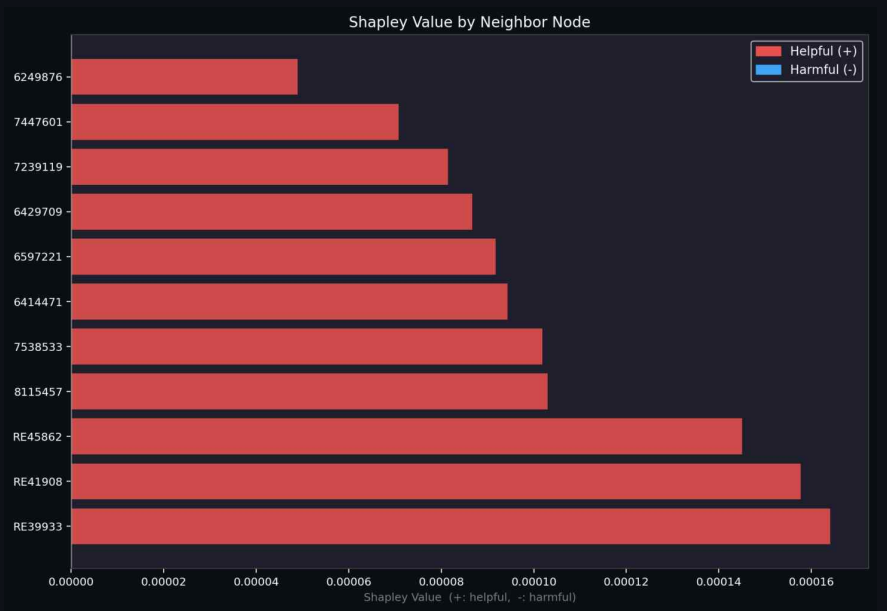


Defendant: 6212079



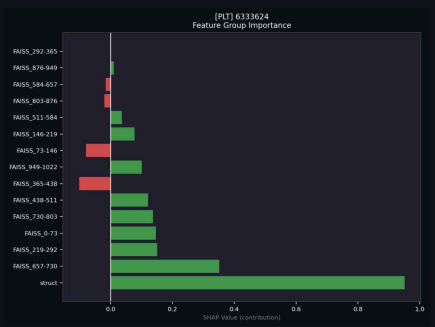
M6. SubgraphX (Monte Carlo Shapley)

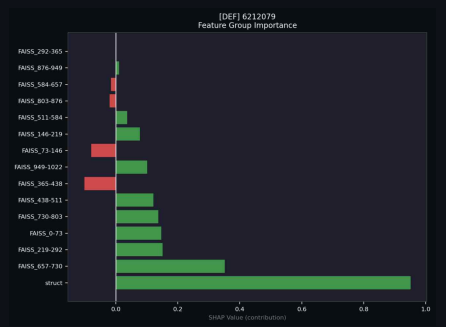
> 이웃 노드들의 Shapley value를 Monte Carlo 샘플링으로 추정합니다
> → 양수: 소송 예측에 기여 / 음수: 예측을 방해하는 노드



M7. GraphSHAP (KernelSHAP Feature Attribution)

> 입력 피처를 그룹으로 나눠 각 그룹의 Shapley value를 KernelSHAP으로 추정합니다
> → struct(3d) vs FAISS 임베딩 구간별로 소송 예측 기여도를 분석





All Test Pair Predictions

#	Plaintiff	Defendant	P(sue)	Pred
1	6333624	6212079	0.9938	0
2	5645571	5879374	0.9883	0
3	5700281	5899926	0.9829	0
4	5984102	5879374	0.9815	0
5	6816496	6901048	0.9813	0
6	5797969	5607454	0.9793	0
7	6816496	6845389	0.9781	0
8	5978115	5959749	0.976	0
9	6088616	5591213	0.9726	0
10	7309135	4478769	0.9718	0